

陈仲泓

电话: 15697580245 性别: 男
籍贯: 广东省肇庆市 出生年月: 1999.05
政治面貌: 共青团员 邮箱: 2538745263@qq.com



教育经历

2025.08-2027.06	澳门大学	人工智能硕士
2018.09-2022.07	中国矿业大学	计算机科学与技术本科 GPA 87/100 (26/139) CET-6

实习经历

暨南大学智科院 x 浙江省文成县	3DGS 低空算法平台底座	后端开发 2026.02-2026.09
------------------	---------------	------------------------

项目背景: 暨南大学与浙江省文成县开展低空技术横向合作(文成一暨南大学低空技术联合实验室),建设低空算法巡检平台,我负责在短周期内**打通**无人机设备接入、巡检任务管理与实时作业链路,为后续场景采集做 3dgs 建模和直播算法做准备。

› **实时通信与安全控制:** 面向无人机巡检场景,通过 **MQTT** 接入 **DJI** 的遥测、设备状态和任务消息,经 **Redis** 跨进程广播后由 **WebSocket** 推送至前端,实现**无人机**位置、电量、在线状态和任务进度的实时同步;同时支持直播控制,并加入权限校验、任务中止和操作审计。

› **算法编排:** 面向无人机巡检视频分析,基于 Google MediaPipe Graph 设计硬件无关的算法编排框架:以携带 Timestamp 的 Packet 作为统一数据契约,将各类视觉处理能力封装为可组合的 Calculator 节点,实现多算法分支的时序同步与结果对齐。

工作经历

瀚博半导体 · 独角兽企业 瀚博创芯科技(深圳)有限公司	NPU SDK/推理平台	推理工具链开发 2022.07-2025.02
---------------------------------	--------------	---------------------------

项目背景: 负责瀚博 AI 芯片(SV100) runtime 之上的软件栈&工具链的设计开发和优化迭代,针对不同能力的用户提供一套统一的高性能易用的开发框架和接口。**深度参与** C++ SDK 研发, **独立负责** Python SDK 侧业务线,推动芯片产品适配**主流推理框架(Triton inference server)**,并支持 SDK 在小红书、阿里云、高视等客户的业务中落地。

› **参与 C++ SDK 研发:** 基于自研 NPU Runtime 接口设计统一 C++ SDK,在原有的 runtime 调用流中抽象出 **Tensor**, **算子**, **模型**, **执行流** 等关键对象,并以 **RAII**、**智能指针**和**编译期类型**检查规范对象生命周期与资源管理。将 Runtime 的 **C Callback** 封装在 SDK 内部,对外提供统一的异步结果获取接口。使用**阻塞通知队列**,接受异步回调结果的**无锁队列**,**协程**处理异步结果,并利用 batch_id/data_id 整理乱序完成的推理结果,使业务侧无需关心底层调度即可按提交顺序获取结果。

› **负责 Python SDK 研发:** 基于 **pybind11** 将 C++ SDK 的核心对象映射为 Python API,封装同步/异步推理、算子输出获取、动态输入 shape 和自定义算子配置;实现 **NumPy** 与 Tensor 的数据转换、C++ 异常到 Python 异常映射,并在同步推理、结果等待等耗时调用中释放 GIL。

› **打通构建与 CI/CD 流程:** 统一 **CMake** 构建入口、第三方依赖和编译配置,打通 C++ 核心库、pybind11 Binding、测试程序及 Python Wheel 的编译链路;接入 **GitLab CI/Jenkins**,串联代码格式检查、C++/Python 测试、Release 构建、安装包打包和制品发布,实现提交后的自动验证与版本化交付。

› **算法端到端落地:** 完成 PyTorch 模型向 C++/NPU 推理链路的迁移与集成,涵盖前后处理及业务接入,并完成 Docker 部署。针对数据拷贝与并行计算瓶颈,采用 OpenCV Mat 内存共享、TBB 并行等方式进行优化;多数场景下 NPU AI Core 利用率达到 97% 以上。

个人项目

PaperLoom 科研文献智能检索工具

个人开源项目

主要负责人 | 2025.12-2026.09

项目背景：传统 RAG 直接基于检索片段生成，容易出现检索范围失控、引用失真等问题，很多同学利用 AI 写综述、做论文引用时，希望每一处引用都能追溯到论文原文的具体出处、页码与段落，同时区分直接引用和转述，避免模型编造。PaperLoom 面向多论文研究，把工具使用、授权范围与证据链纳入同一 Agent 运行框架。除前端展示外，系统同时通过 MCP Server 暴露能力，供 Copilot, Codex 等 Agent 应用调用。体验地址：<https://paperloom.me>；源码地址：<https://github.com/CHZarles/paperloom>

- › **设计 Harness**：将论文研究拆分为发现、检索、精读等阶段，由 Agent 根据任务调用对应工具，并维护多轮研究上下文。
- › **实现混合检索链路**：分别召回 BM25 和 Embedding 结果，通过 RRF 融合排序，再结合权限 Scope 过滤可访问内容；为检索片段保留文档、页码和段落信息，支持引用回溯到原文。
- › **异步 PDF 入库链路**：使用 MinIO 存储文件、Kafka 驱动异步解析，结合 Redis 和 MySQL 管理处理状态，完成从上传到索引构建的流程。
- › **Trace 与评测机制**：采集 Agent 工具调用、检索结果、引用证据、耗时和错误等信息；围绕任务完成度、检索质量和引用准确性构建评测集，并根据评测结果定位工具编排和检索链路问题，持续迭代 Harness。

专业技能

编程与构建：C++、Python、Java、pybind11、CMake、GitLab CI、Python Wheel、Docker

推理与视觉：NPU Runtime、PyTorch、Triton Inference Server、OpenCV、TBB、MediaPipe

Agent 与检索：OpenAI SDK、Agent Harness、RAG、MCP、BM25、Embedding、Trace 与评测

后端与基础设施：Spring Boot、FastAPI、MQTT、Redis、WebSocket、MinIO、Kafka、MySQL