

工作经历

瀚博半导体

2022/07 – 2025/07

项目一：自研 **NPU** 高性能推理 **SDK** 与 **Python** 绑定开发

- C++ CMake pybind11 libgo Lock-free Queue RAII
- 架构抽象与资源管控：针对底层 C 运行时接口原始、易泄漏的问题，基于 CMake 构建统一的 C++ SDK；运用 RAII 机制与智能指针 对模型生命周期、执行流上下文及 Tensor/Image Buffer 进行全局纳管，杜绝内存泄漏与异常崩溃。
 - 高并发异步推理管道：设计同步/异步双模推理接口，引入无锁队列消除多线程数据争用，结合 libgo 协程封装底层异步回调与阻塞等 待逻辑，提供高吞吐的 RunAsync 与结果消费 Poller 机制。
 - 跨语言无缝交付：基于 pybind11 完成 C++ 核心类、数据结构及异常捕获到 Python 模块的映射，降低上层算法与应用工程师的接入 门槛。
 - 商业级交付验证：SDK 作为一体化解决方案的核心组件，成功交付至阿里云、小红书、高视科技等头部客户，并在内部压测及生产业 务中持续稳定运行。

瀚博半导体

2022/07 – 2025/07

项目二：端到端 **AI** 业务管线构建

- Python C++ MediaPipe OpenCV PyTorch YOLOv8
- 端到端算法流程落地：负责目标检测（YOLOv8）、特征提取（ResNet）及多目标跟踪（ByteTrack）等算法在自研硬件上的全流程打 通；基于 OpenCV、NumPy、LibTorch 编写高性能前后处理及 NPU 协同推理代码。
 - 复杂业务流编排：深入 Google MediaPipe，根据业务需求开发多种 Calculator 节点，实现数据输入、前后处理、多模型串联推理及跟 踪逻辑的计算图编排。
 - 环境容器化与部署标准化：构建 Docker 镜像并收敛依赖，整合 NPU 运行时及 C++/Python 依赖；规范模型仓库挂载与数据卷映射， 确保不同环境下一致、快速部署。
 - 工程文档与交付支持：编写端到端调用范例与接入文档，协助业务团队及外部客户快速完成算法接入和问题排查。

项目经历

PaperLoom 论文智能阅读与可溯源问答系统 [paperloom.me](#)

- OpenAI Agents SDK Java 17 / Spring Boot Qdrant MySQL Kafka MinIO WebSocket
- 面向科研论文阅读场景开发 Agentic RAG 问答系统。采用 Java/Spring Boot（业务边界与数据权威）+ Python（Agent 运行时）分层架 构，确保回答中的每一句论述均可回溯至原始 PDF 的页码、章节与段落。
- Agent** 工具链与引用防伪校验：设计“候选检索 → 原文精读 → 引用生成 → 最终提交”调用链；维护已读原文清单并以代码规则校 验引用编号，从机制上杜绝虚假引用。
 - 数据分层与结构化建模：对 PDF 解析产物进行领域建模，统一为带页码、章节层级、表格/图表及坐标的数据结构；以 Qdrant 导航候 选位置、MySQL 提供权威原文。
 - 权限锁定与异步解析流水线：以数据库锁固定会话论文范围；基于 Kafka、MinIO、MySQL 状态机构建分片上传、异步解析与向量索 引流水线，通过唯一约束和条件更新保障幂等。
 - 流式交互与离线评测：基于 Spring WebSocket 流式推送 Agent 思考过程、工具状态与答案，支持任务中断；搭建 Golden Cases，分 层统计检索召回率、阅读覆盖率和引用准确率。

教育经历

澳门大学 人工智能 · 硕士

2025/08 – 2027/06

中国矿业大学 计算机科学与技术 · 本科, GPA: 87/100, 专业排名: 26/139

2018/09 – 2022/07