

中国

工作经历

瀚博半导体

2022/07 – 2025/07

项目一：自研 **NPU** 高性能推理 **SDK** 与 **Python** 绑定开发

C++ CMake Python pybind11 NumPy Buffer Protocol moodycamel libgo RAI1

面向公司自研 NPU 芯片的推理接入需求，针对底层 C Runtime 接口原始、异步回调侵入性强及手动管理 Buffer 易泄漏等问题，基于 CMake 设计并实现跨语言 C++/Python 推理 SDK。将底层异步回调转换为拉取式结果接口，并提供与 NumPy 互通的 Pythonic API，为算法与应用团队提供高效、内存安全的推理开发套件。

- 异步结果通道与拉取式接口：接管 C Runtime completion callback，以 moodycamel 无锁并发队列作为跨线程结果通道，并通过 ProducerToken 优化回调路径；业务线程仅需调用 RunAsync() 提交任务，通过 GetOutput(timeout) 阻塞等待并拉取完整 batch 结果。
- 回调解耦与异步调度：回调函数仅负责组装 Result 并高效入队，与业务结果处理严格解耦；SDK 内部结合 libgo 承载异步调度基础设施，避免底层回调逻辑侵入上层业务代码。
- Buffer** 生命周期安全闭环：使用 RAI1 与智能指针封装模型句柄、执行流上下文及 Tensor/Image Buffer，任务对象自动持有执行期间所需资源；设计 CloseInput() → 持续 GetOutput() 至 EOF → WaitUntilDone() 的收尾状态机，待 Runtime 回调静止、消费端退出后再销毁队列与上下文，规避悬垂指针和内存泄漏。
- Pythonic** 跨语言封装：基于 pybind11 封装 C++ 类、上下文与推理生命周期，提供上下文管理器 with、流式迭代和异常映射，为上层应用屏蔽底层并发与内存管理细节。
- NumPy** 互通与并发安全：基于 Python Buffer Protocol 实现 Tensor Buffer 与 numpy.ndarray 的零拷贝/低开销互通；在 GetOutput() 阻塞路径显式释放 GIL (py::gil_scoped_release)，避免阻塞 Python 主线程及并发业务逻辑。
- 商业级交付验证：SDK 作为一体化解决方案核心组件，交付至阿里云、小红书、高视科技等客户，并在内部算法压测及生产业务中持续运行。

瀚博半导体

2022/07 – 2025/07

项目二：端到端 **AI** 业务管线构建

Python C++ MediaPipe OpenCV PyTorch YOLOv8

- 端到端算法流程落地：负责目标检测（YOLOv8）、特征提取（ResNet）及多目标跟踪（ByteTrack）等算法在自研硬件上的全流程打通；基于 OpenCV、NumPy、LibTorch 编写高性能前后处理及 NPU 协同推理代码。
- 复杂业务流编排：深入 Google MediaPipe，根据业务需求开发多种 Calculator 节点，实现数据输入、前后处理、多模型串联推理及跟踪逻辑的计算图编排。
- 环境容器化与部署标准化：构建 Docker 镜像并收敛依赖，整合 NPU 运行时及 C++/Python 依赖；规范模型仓库挂载与数据卷映射，确保不同环境下一致、快速部署。
- 工程文档与交付支持：编写端到端调用范例与接入文档，协助业务团队及外部客户快速完成算法接入和问题排查。

项目经历

PaperLoom 论文智能阅读与可溯源问答系统 [paperloom.me](#)

OpenAI Agents SDK Java 17 / Spring Boot Qdrant MySQL Kafka MinIO WebSocket

面向科研论文阅读场景开发 Agentic RAG 问答系统。采用 Java/Spring Boot（业务边界与数据权威）+ Python（Agent 运行时）分层架构，确保回答中的每一句论述均可回溯至原始 PDF 的页码、章节与段落。

- Agent** 工具链与引用防伪校验：设计“候选检索 → 原文精读 → 引用生成 → 最终提交”调用链；维护已读原文清单并以代码规则校验引用编号，从机制上杜绝虚假引用。
- 数据分层与结构化建模：对 PDF 解析产物进行领域建模，统一为带页码、章节层级、表格/图表及坐标的数据结构；以 Qdrant 导航候选位置、MySQL 提供权威原文。
- 权限锁定与异步解析流水线：以数据库锁固定会话论文范围；基于 Kafka、MinIO、MySQL 状态机构建分片上传、异步解析与向量索引流水线，通过唯一约束和条件更新保障幂等。
- 流式交互与离线评测：基于 Spring WebSocket 流式推送 Agent 思考过程、工具状态与答案，支持任务中断；搭建 Golden Cases，分层统计检索召回率、阅读覆盖率和引用准确率。

教育经历

澳门大学 人工智能 · 硕士

2025/08 – 2027/06

中国矿业大学 计算机科学与技术 · 本科, GPA: 87/100, 专业排名: 26/139

2018/09 – 2022/07